

Análise de Componentes Principais

Introdução

Um problema central na análise de dados multivariados é a **redução da dimensionalidade**: é possível descrever com precisão a informação contida nos dados mensurados em p variáveis utilizando um conjunto $r < p$ de novas variáveis, perdendo a menor quantidade de informação possível?

Introdução

Um problema central na análise de dados multivariados é a **redução da dimensionalidade**: é possível descrever com precisão a informação contida nos dados mensurados em p variáveis utilizando um conjunto $r < p$ de novas variáveis, perdendo a menor quantidade de informação possível?

A **análise de componentes principais** tem este objetivo: dadas n observações de p variáveis, se analisa se é possível representar adequadamente esta informação com um número menor de variáveis construídas como **combinações lineares** das variáveis originais.

O Problema...

Dado um conjunto de variáveis $\mathbf{x} = [X_1 \ X_2 \ \cdots \ X_p]^t$, podemos encontrar outro conjunto de variáveis $\mathbf{y} = [Y_1 \ Y_2 \ \cdots \ Y_r]^t$, dadas por

$$Y_i = \sum_{j=1}^p a_{ij} X_j, \quad i = 1, \dots, r < p$$

de tal forma que a informação contida em $\mathbf{x}$ esteja sendo bem representada por $\mathbf{y}$?

Algumas questões

Vamos encontrar combinações lineares para representar informação.

Algumas questões

Vamos encontrar combinações lineares para representar informação.

O que é **informação**?

Algumas questões

Vamos encontrar combinações lineares para representar informação.

O que é **informação**?

Informação $\implies$ Variância: quanto maior a variabilidade, maior a informação contida nos dados, maior a variância dos dados

Algumas questões

Outra questão importante:

Algumas questões

Outra questão importante:

O que é **uma boa representação da informação?**

Algumas questões

Outra questão importante:

O que é **uma boa representação da informação?**

Boa representação da informação $\implies$ tomar as componentes de y que assegurem uma variância similar à de x

Esquemáticamente

Nestas condições, temos que buscar **combinações lineares** y das variáveis x de forma que se *maximize* a **variância**

Esquemáticamente

Nestas condições, temos que buscar **combinações lineares** y das variáveis x de forma que se *maximize* a **variância**

Variáveis Originais		Combinações Lineares
X_1		Y_1
X_2		Y_2
$\vdots$		$\vdots$
X_r	$\Rightarrow$	Y_r
$\vdots$		$\vdots$
X_p		Y_p

Esquemáticamente

Nestas condições, temos que buscar **combinações lineares** y das variáveis x de forma que se *maximize* a **variância**

Variáveis Originais		Combinações Lineares
X_1		Y_1
X_2		Y_2
$\vdots$		$\vdots$
X_r	$\Rightarrow$	Y_r
$\vdots$		$\vdots$
X_p		Y_p

$\text{Var}[\mathbf{y}]$: Máxima

Esquemáticamente

Ideia básica da técnica de Análise de Componentes Principais:

Esquemáticamente

Ideia básica da técnica de Análise de Componentes Principais:

Variáveis Originais		Componentes Principais
X_1	ACP	Y_1
X_2	$\Rightarrow$	Y_2
$\vdots$		$\vdots$
X_p		Y_r
		$\vdots$
		Y_p

Esquemáticamente


Ideia básica da técnica de Análise de Componentes Principais:

Variáveis Originais		Componentes Principais
X_1	ACP	Y_1
X_2	$\Rightarrow$	Y_2
$\vdots$		$\vdots$
X_p		Y_r
		$\vdots$
		Y_p

As r primeiras componentes resumem, por exemplo, 80% do comportamento geral das p variáveis originais.

Principais objetivos

- Redução da dimensionalidade dos dados, projetando-os em uma dimensão $r < p$;



Principais objetivos

- Obtenção de combinações interpretáveis: determinar índices e produzir escores com base nos resultados avaliados para as p variáveis;


IDH

ÍNDICE DE DESENVOLVIMENTO HUMANO



Principais objetivos

- Descrição e entendimento da estrutura de correlação entre as variáveis, através de algumas combinações lineares das mesmas.



Componentes Principais: o que são?

Algebricamente: são combinações lineares das p variáveis originais, $X_1, X_2, \dots, X_p$.

Componentes Principais: o que são?

Algebricamente: são combinações lineares das p variáveis originais, $X_1, X_2, \dots, X_p$.

Geometricamente: são as coordenadas dos pontos amostrais em um sistema de eixos obtido pela rotação do sistema de eixos original, na direção de variabilidade máxima.

Componentes Principais: alguns comentários

- ▶ Não pressupõe normalidade dos dados, embora componentes derivadas de populações normais tenham interpretações úteis.

Componentes Principais: alguns comentários

- ▶ Não pressupõe normalidade dos dados, embora componentes derivadas de populações normais tenham interpretações úteis.
- ▶ Com frequência, revela relações insuspeitas. Pode permitir interpretações que não seriam obtidas preliminarmente.

Componentes Principais: alguns comentários

- ▶ Não pressupõe normalidade dos dados, embora componentes derivadas de populações normais tenham interpretações úteis.
- ▶ Com frequência, revela relações insuspeitas. Pode permitir interpretações que não seriam obtidas preliminarmente.
- ▶ Em algumas aplicações, os componentes da ACP configuram o objetivo final do estudo. Em outras, servem como passo intermediário para realização de outras análises, como regressão, classificação, agrupamento, etc...

Componentes Principais: como obtê-los?

- ▶ Sejam $X_1, X_2, \dots, X_p$ as variáveis originais

Componentes Principais: como obtê-los?

- ▶ Sejam $X_1, X_2, \dots, X_p$ as variáveis originais
- ▶ A ideia é encontrar um novo conjunto de variáveis $Y_1, Y_2, \dots, Y_p$, tais que:

$$\text{Var}[Y_1] \geq \text{Var}[Y_2] \geq \dots \geq \text{Var}[Y_p]$$

Componentes Principais: como obtê-los?

- ▶ Sejam $X_1, X_2, \dots, X_p$ as variáveis originais
- ▶ A ideia é encontrar um novo conjunto de variáveis $Y_1, Y_2, \dots, Y_p$, tais que:

$$\text{Var}[Y_1] \geq \text{Var}[Y_2] \geq \dots \geq \text{Var}[Y_p]$$

- ▶ Vamos tomar cada nova variável Y_i , $i = 1, \dots, p$, como uma combinação linear das variáveis originais $\mathbf{x}$:

$$Y_i = a_{i1}X_1 + a_{i2}X_2 + \dots + a_{ip}X_p = \mathbf{a}_i^t \mathbf{x}$$

Componentes Principais: como obtê-los?

- Para fixar problemas de escala, adicionamos uma primeira restrição aos vetores $\mathbf{a}_i$:

$$\mathbf{a}_i^t \mathbf{a}_i = \sum_{j=1}^p a_{ij}^2 = 1$$

Componentes Principais: como obtê-los?

- ▶ Para fixar problemas de escala, adicionamos uma primeira restrição aos vetores $\mathbf{a}_i$:

$$\mathbf{a}_i^t \mathbf{a}_i = \sum_{j=1}^p a_{ij}^2 = 1$$

- ▶ Para evitar que duas variáveis Y_i e Y_k , $i \neq k$, $i, k = 1, \dots, p$, compartilhem informação, adicionamos uma segunda restrição aos vetores $\mathbf{a}_i$:

$$\mathbf{a}_i^t \mathbf{a}_k = \sum_{j=1}^p a_{ij} a_{kj} = 0$$

Componentes Principais: como obtê-los?

- ▶ Para fixar problemas de escala, adicionamos uma primeira restrição aos vetores $\mathbf{a}_i$:

$$\mathbf{a}_i^t \mathbf{a}_i = \sum_{j=1}^p a_{ij}^2 = 1$$

- ▶ Para evitar que duas variáveis Y_i e Y_k , $i \neq k$, $i, k = 1, \dots, p$, compartilhem informação, adicionamos uma segunda restrição aos vetores $\mathbf{a}_i$:

$$\mathbf{a}_i^t \mathbf{a}_k = \sum_{j=1}^p a_{ij} a_{kj} = 0$$

Garantia: ortogonalidade, componentes não correlacionadas, independência

Componentes Principais: como obtê-los?

Primeira Componente Principal

$$Y_1 = a_{11}X_1 + a_{12}X_2 + \cdots + a_{1p}X_p = a_1^t \mathbf{x}$$

Componentes Principais: como obtê-los?

Primeira Componente Principal

$$Y_1 = a_{11}X_1 + a_{12}X_2 + \cdots + a_{1p}X_p = a_1^t \mathbf{x}$$

Objetivo: Encontrar $a_1^t = [a_{11} \ a_{12} \ \cdots \ a_{1p}]^t$ tal que:

$\text{Var}[Y_1]$ seja máxima

Componentes Principais: como obtê-los?

Primeira Componente Principal

$$Y_1 = a_{11}X_1 + a_{12}X_2 + \cdots + a_{1p}X_p = a_1^t \mathbf{x}$$

Objetivo: Encontrar $a_1^t = [a_{11} \ a_{12} \ \cdots \ a_{1p}]^t$ tal que:

$\text{Var}[Y_1]$ seja máxima

Sujeita à restrição:

$$a_1^t a_1 = a_{11}^2 + a_{12}^2 + \cdots + a_{1p}^2 = 1$$

Componentes Principais: como obtê-los?

Segunda Componente Principal

$$Y_2 = a_{21}X_1 + a_{22}X_2 + \cdots + a_{2p}X_p = a_2^t \mathbf{x}$$

Componentes Principais: como obtê-los?

Segunda Componente Principal

$$Y_2 = a_{21}X_1 + a_{22}X_2 + \cdots + a_{2p}X_p = a_2^t \mathbf{x}$$

Objetivo: Encontrar $a_2^t = [a_{21} \ a_{22} \ \cdots \ a_{2p}]^t$ tal que:

$\text{Var}[Y_2]$ seja máxima

Componentes Principais: como obtê-los?

Segunda Componente Principal

$$Y_2 = a_{21}X_1 + a_{22}X_2 + \cdots + a_{2p}X_p = a_2^t \mathbf{x}$$

Objetivo: Encontrar $a_2^t = [a_{21} \ a_{22} \ \cdots \ a_{2p}]^t$ tal que:

$\text{Var}[Y_2]$ seja máxima

Sujeita à restrição:

$$a_2^t a_2 = a_{21}^2 + a_{22}^2 + \cdots + a_{2p}^2 = 1$$

$$\text{Cov}[Y_1, Y_2] = 0$$

Componentes Principais: como obtê-los?

i-ésima Componente Principal

$$Y_i = a_{i1}X_1 + a_{i2}X_2 + \cdots + a_{ip}X_p = a_i^t \mathbf{x}$$

Componentes Principais: como obtê-los?

i-ésima Componente Principal

$$Y_i = a_{i1}X_1 + a_{i2}X_2 + \cdots + a_{ip}X_p = a_i^t \mathbf{x}$$

Objetivo: Encontrar $a_i^t = [a_{i1} \ a_{i2} \ \cdots \ a_{ip}]^t$ tal que:

$\text{Var}[Y_i]$ seja máxima

Componentes Principais: como obtê-los?

i-ésima Componente Principal

$$Y_i = a_{i1}X_1 + a_{i2}X_2 + \cdots + a_{ip}X_p = a_i^t \mathbf{x}$$

Objetivo: Encontrar $a_i^t = [a_{i1} \ a_{i2} \ \cdots \ a_{ip}]^t$ tal que:

$\text{Var}[Y_i]$ seja máxima

Sujeita à restrição:

$$a_i^t a_i = a_{i1}^2 + a_{i2}^2 + \cdots + a_{ip}^2 = 1$$

$$\text{Cov}[Y_i, Y_k] = 0, \text{ para } k < i$$

A escolha dos vetores a_i

- Considere o vetor aleatório p-variado $\mathbf{x} = [X_1 \ X_2 \ \cdots \ X_p]^t$ com vetor de médias μ e matriz de covariâncias Σ , positiva definida (todos os seus autovalores são positivos), sendo

$$\mu = [\mu_1 \ \mu_2 \ \cdots \ \mu_p]^t \quad \text{e} \quad \Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_{pp} \end{bmatrix}$$

A escolha dos vetores a_i

- Considere o vetor aleatório p-variado $\mathbf{x} = [X_1 \ X_2 \ \cdots \ X_p]^t$ com vetor de médias μ e matriz de covariâncias Σ , positiva definida (todos os seus autovalores são positivos), sendo

$$\mu = [\mu_1 \ \mu_2 \ \cdots \ \mu_p]^t \quad \text{e} \quad \Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_{pp} \end{bmatrix}$$

- Para determinação dos componentes principais, com base no que foi exposto, usaremos o seguinte teorema:

A escolha dos vetores a_i

Teorema - Maximização de formas quadráticas: Seja B uma matriz positiva definida com autovalores $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p > 0$ e autovetores associados normalizados $e_1, e_2, \dots, e_p$. Então:

$$\max_{\mathbf{x} \neq 0} \frac{\mathbf{x}^t B \mathbf{x}}{\mathbf{x}^t \mathbf{x}} = \lambda_1, \text{ obtido quando } \mathbf{x} = e_1;$$

$$\min_{\mathbf{x} \neq 0} \frac{\mathbf{x}^t B \mathbf{x}}{\mathbf{x}^t \mathbf{x}} = \lambda_p, \text{ obtido quando } \mathbf{x} = e_p.$$

A escolha dos vetores a_i

Teorema - Maximização de formas quadráticas: Seja B uma matriz positiva definida com autovalores $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p > 0$ e autovetores associados normalizados $e_1, e_2, \dots, e_p$. Então:

$$\max_{\mathbf{x} \neq 0} \frac{\mathbf{x}^t B \mathbf{x}}{\mathbf{x}^t \mathbf{x}} = \lambda_1, \text{ obtido quando } \mathbf{x} = e_1;$$

$$\min_{\mathbf{x} \neq 0} \frac{\mathbf{x}^t B \mathbf{x}}{\mathbf{x}^t \mathbf{x}} = \lambda_p, \text{ obtido quando } \mathbf{x} = e_p.$$

► Adicionalmente,

$$\max_{\mathbf{x} \perp e_1, e_1, \dots, e_k} \frac{\mathbf{x}^t B \mathbf{x}}{\mathbf{x}^t \mathbf{x}} = \lambda_{k+1}, \text{ obtido quando } \mathbf{x} = e_{k+1}.$$

A escolha dos vetores a_i

Assim, no contexto de componentes principais, seja $\mathbf{x} = [X_1 \ X_2 \ \dots \ X_p]^t$ um vetor aleatório. Seja Σ a matriz de variâncias e covariâncias e $(\lambda_1, e_1), (\lambda_2, e_2), \dots, (\lambda_p, e_p)$ seus autovalores e autovetores, tal que $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p > 0$. Então:

$$\max_{a \neq 0} \frac{a^t \Sigma a}{a^t a} = \max_{a \neq 0} (a^t \Sigma a) = \lambda_1, \text{ obtido quando } a = e_1;$$

$$\min_{a \neq 0} \frac{a^t \Sigma a}{a^t a} = \min_{a \neq 0} (a^t \Sigma a) = \lambda_p, \text{ obtido quando } a = e_p.$$

A escolha dos vetores a_i

► Adicionalmente,

$$\max_{a \perp e_1, e_1, \dots, e_k} \frac{a^t \Sigma a}{a^t a} = \max_{a \perp e_1, e_1, \dots, e_k} (a^t \Sigma a) = \lambda_{k+1}, \text{ obtido quando } a = e_{k+1}.$$

A escolha dos vetores a_i

- ▶ Uma escolha interessante para os vetores de constantes a_i , $i = 1, \dots, p$ são os **autovetores normalizados** e_i da matriz Σ .

A escolha dos vetores a_i

- ▶ Uma escolha interessante para os vetores de constantes a_i , $i = 1, \dots, p$ são os **autovetores normalizados** e_i da matriz Σ .
- ▶ Dessa forma, podemos definir a i -ésima componente principal da matriz Σ , $i = 1, \dots, p$ como sendo

A escolha dos vetores a_i

- ▶ Uma escolha interessante para os vetores de constantes a_i , $i = 1, \dots, p$ são os **autovetores normalizados** e_i da matriz Σ .
- ▶ Dessa forma, podemos definir a i -ésima componente principal da matriz Σ , $i = 1, \dots, p$ como sendo

$$Y_i = e_i^t \mathbf{x} = e_{i1}X_1 + e_{i2}X_2 + \dots + e_{ip}X_p$$

Componentes Principais: propriedades

- A esperança e a variância da componente Y_i são respectivamente dadas por:

$$\begin{aligned} E[Y_i] &= E[e_{i1}X_1 + e_{i2}X_2 + \cdots + e_{ip}X_p] \\ &= e_{i1}E[X_1] + e_{i2}E[X_2] + \cdots + e_{ip}E[X_p] \\ &= e_{i1}\mu_1 + e_{i2}\mu_2 + \cdots + e_{ip}\mu_p \\ &= e_i^\top \mu \end{aligned}$$

Componentes Principais: propriedades

- A esperança e a variância da componente Y_i são respectivamente dadas por:

$$\begin{aligned} E[Y_i] &= E[e_{i1}X_1 + e_{i2}X_2 + \cdots + e_{ip}X_p] \\ &= e_{i1}E[X_1] + e_{i2}E[X_2] + \cdots + e_{ip}E[X_p] \\ &= e_{i1}\mu_1 + e_{i2}\mu_2 + \cdots + e_{ip}\mu_p \\ &= e_i^\top \mu \end{aligned}$$

$$\text{Var}[Y_i] = \text{Var}[e_i^t \mathbf{x}] = e_i^t \text{Var}[\mathbf{x}] e_i = e_i^t \Sigma e_i = e_i^t \lambda_i e_i = e_i^t e_i \lambda_i = \lambda_i$$

Na forma matricial

► Sejam O a matriz dos autovetores normalizados da matriz Σ , isto é,

$$O = \begin{bmatrix} e_{11} & e_{21} & \cdots & e_{p1} \\ e_{12} & e_{22} & \cdots & e_{p2} \\ \vdots & \vdots & \ddots & \vdots \\ e_{1p} & e_{2p} & \cdots & e_{pp} \end{bmatrix} = [e_1 \quad e_2 \quad \cdots \quad e_p]$$

e y o vetor das componentes principais. Então, $y = O^t \mathbf{x}$ e a matriz de covariâncias de y será:

$$\text{Var}[y] = \text{Var}[O^t \mathbf{x}] = O^t \text{Var}[\mathbf{x}] O = O^t \Sigma O = \Lambda$$

Na forma matricial

sendo

$$\Lambda = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_p \end{bmatrix}$$

ou ainda, $\Sigma = O\Lambda O^t = \sum_{i=1}^p \lambda_i e_i e_i^t$, uma vez que O é uma matriz ortogonal tal que

$OO^t = O^t O = I$. Estes resultados são conhecidos como **Teorema da decomposição espectral**.

Variabilidade explicada

Variável	Variância	Componente	Variância
X_1	σ_{11}	Y_1	λ_1
X_2	σ_{22}	Y_2	λ_2
$\vdots$	$\vdots$	$\vdots$	$\vdots$
X_p	σ_{pp}	Y_p	λ_p
Total	$\sigma_T^2 = \sum_{j=1}^p \sigma_{jj} = \text{tr}(\Sigma)$	Total	$\lambda_T = \sum_{j=1}^p \lambda_j = \text{tr}(\Lambda)$

Variabilidade explicada

Variável	Variância	Componente	Variância
X_1	σ_{11}	Y_1	λ_1
X_2	σ_{22}	Y_2	λ_2
$\vdots$	$\vdots$	$\vdots$	$\vdots$
X_p	σ_{pp}	Y_p	λ_p
Total	$\sigma_T^2 = \sum_{j=1}^p \sigma_{jj} = \text{tr}(\Sigma)$	Total	$\lambda_T = \sum_{j=1}^p \lambda_j = \text{tr}(\Lambda)$

$$\text{tr}(\Sigma) = \text{tr}(\mathbf{O}\mathbf{\Lambda}\mathbf{O}^t) = \text{tr}(\mathbf{\Lambda}\mathbf{O}^t\mathbf{O}) = \text{tr}(\mathbf{\Lambda}\mathbf{I}) = \text{tr}(\mathbf{\Lambda})$$

Variabilidade explicada

Variável	Variância	Componente	Variância
X_1	σ_{11}	Y_1	λ_1
X_2	σ_{22}	Y_2	λ_2
$\vdots$	$\vdots$	$\vdots$	$\vdots$
X_p	σ_{pp}	Y_p	λ_p
Total	$\sigma_T^2 = \sum_{j=1}^p \sigma_{jj} = \text{tr}(\Sigma)$	Total	$\lambda_T = \sum_{j=1}^p \lambda_j = \text{tr}(\Lambda)$

$$\text{tr}(\Sigma) = \text{tr}(\mathbf{O}\Lambda\mathbf{O}^t) = \text{tr}(\Lambda\mathbf{O}^t\mathbf{O}) = \text{tr}(\Lambda\mathbf{I}) = \text{tr}(\Lambda)$$

$$\sigma_T^2 = \lambda_T$$

Variabilidade explicada

- Pode-se então concluir que a **j-ésima componente explica**

$$\frac{\text{Var}[Y_j]}{\text{Variância Total de X}} = \frac{\lambda_j}{\text{tr}(\Sigma)} = \frac{\lambda_j}{\sum_{i=1}^p \lambda_i}$$

da variação total original, e ainda, que as r **primeiras** componentes explicam

$$\frac{\sum_{j=1}^r \text{Var}[Y_j]}{\text{Variância Total de X}} = \frac{\sum_{j=1}^r \lambda_j}{\text{tr}(\Sigma)} = \frac{\sum_{j=1}^r \lambda_j}{\sum_{i=1}^p \lambda_i}$$

da variação total.

Variabilidade explicada

- ▶ Busca-se analisar um conjunto menor de variáveis sem perder muita informação sobre a estrutura de variabilidade original

Variabilidade explicada

- ▶ Busca-se analisar um conjunto menor de variáveis sem perder muita informação sobre a estrutura de variabilidade original
- ▶ Aproximação de Σ : Analisando as r primeiras componentes principais

$$\Sigma \approx \sum_{i=1}^r \lambda_i e_i e_i^t$$

Variabilidade explicada

- ▶ Busca-se analisar um conjunto menor de variáveis sem perder muita informação sobre a estrutura de variabilidade original
- ▶ Aproximação de Σ : Analisando as r primeiras componentes principais

$$\Sigma \approx \sum_{i=1}^r \lambda_i e_i e_i^t$$

- ▶ Cada parcela da soma envolve uma matriz de dimensão $p \times p$ correspondente apenas à informação da j -ésima componente principal

Correlação com as variáveis originais

- ▶ Os coeficientes de correlação entre a j -ésima variável e a i -ésima componente principal é dada por:

$$\rho_{Y_i, X_j} = \frac{e_{ij} \sqrt{\lambda_i}}{\sqrt{\sigma_{jj}}}$$

Correlação com as variáveis originais

- ▶ Os coeficientes de correlação entre a j -ésima variável e a i -ésima componente principal é dada por:

$$\rho_{Y_i, X_j} = \frac{e_{ij} \sqrt{\lambda_i}}{\sqrt{\sigma_{jj}}}$$

- ▶ As correlações medem unicamente a importância de uma variável individual sem considerar a influência das demais. Não medem a importância de X_i na presença de outras variáveis.

Correlação com as variáveis originais

- ▶ Os coeficientes de correlação entre a j -ésima variável e a i -ésima componente principal é dada por:

$$\rho_{Y_i, X_j} = \frac{e_{ij} \sqrt{\lambda_i}}{\sqrt{\sigma_{jj}}}$$

- ▶ As correlações medem unicamente a importância de uma variável individual sem considerar a influência das demais. Não medem a importância de X_i na presença de outras variáveis.
- ▶ Os coeficientes (**cargas**) dos componentes (e_{ij}), seus sinais e magnitudes, permitem interpretar os componentes e avaliar a importância das variáveis em sua constituição.

Estimação das Componentes Principais

- Em geral, Σ é estimada por S

$$S = \begin{bmatrix} s_{11} & s_{12} & \cdots & s_{1p} \\ s_{21} & s_{22} & \cdots & s_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ s_{p1} & s_{p2} & \cdots & s_{pp} \end{bmatrix}$$

Estimação das Componentes Principais

- ▶ Em geral, Σ é estimada por S

$$S = \begin{bmatrix} s_{11} & s_{12} & \cdots & s_{1p} \\ s_{21} & s_{22} & \cdots & s_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ s_{p1} & s_{p2} & \cdots & s_{pp} \end{bmatrix}$$

- ▶ Autovalores de S : $\hat{\lambda}_1, \hat{\lambda}_2, \dots, \hat{\lambda}_p$

Estimação das Componentes Principais

- ▶ Em geral, Σ é estimada por S

$$S = \begin{bmatrix} s_{11} & s_{12} & \cdots & s_{1p} \\ s_{21} & s_{22} & \cdots & s_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ s_{p1} & s_{p2} & \cdots & s_{pp} \end{bmatrix}$$

- ▶ Autovalores de S : $\hat{\lambda}_1, \hat{\lambda}_2, \dots, \hat{\lambda}_p$
- ▶ Autovetores de S : $\hat{e}_1, \hat{e}_2, \dots, \hat{e}_p$

Estimação das Componentes Principais

- Estimação da j -ésima componente principal de S :

$$\hat{Y}_j = \hat{e}_j^t \mathbf{x} = \hat{e}_{j1}X_1 + \hat{e}_{j2}X_2 + \cdots + \hat{e}_{jp}X_p, \quad j = 1, 2, \dots, p$$

Estimação das Componentes Principais

- ▶ Estimação da j -ésima componente principal de S :

$$\hat{Y}_j = \hat{e}_j^t \mathbf{x} = \hat{e}_{j1}X_1 + \hat{e}_{j2}X_2 + \cdots + \hat{e}_{jp}X_p, \quad j = 1, 2, \dots, p$$

- ▶ Componentes principais amostrais - Propriedades

- ▶ Variância: $\text{Var}(\hat{Y}_j) = \hat{\lambda}_j$
- ▶ Covariância entre as componentes: $\text{Cov}(\hat{Y}_j, \hat{Y}_k) = 0, \quad j \neq k$
- ▶ Variância total estimada explicada pela componente:

$$\frac{\text{Var}(\hat{Y}_j)}{\text{Variância total estimada de } \mathbf{x}} = \frac{\hat{\lambda}_j}{\text{tr}(S)} = \frac{\hat{\lambda}_j}{\sum_{i=1}^p \hat{\lambda}_i}$$

Estimação das Componentes Principais

- Correlação estimada entre componente e variável:

$$r_{\hat{Y}_j, \hat{X}_k} = \frac{\hat{e}_{jk} \sqrt{\hat{\lambda}_j}}{\sqrt{\sigma_{kk}}}$$

Estimação das Componentes Principais

- ▶ Correlação estimada entre componente e variável:

$$r_{\hat{Y}_j, \hat{X}_k} = \frac{\hat{e}_{jk} \sqrt{\hat{\lambda}_j}}{\sqrt{\sigma_{kk}}}$$

- ▶ Decomposição espectral de S :

$$S = \sum_{j=1}^p \hat{\lambda}_j \hat{e}_j \hat{e}_j^t$$

Estimação das Componentes Principais

- ▶ Aproximação de S pelas r primeiras componentes

$$S \approx \sum_{j=1}^r \hat{\lambda}_j \hat{e}_j \hat{e}_j^t$$

Estimação das Componentes Principais

- ▶ Aproximação de S pelas r primeiras componentes

$$S \approx \sum_{j=1}^r \hat{\lambda}_j \hat{e}_j \hat{e}_j^t$$

- ▶ Escores das componentes
 - ▶ Valor das componentes para cada elemento amostral
 - ▶ Na prática, o uso das componentes relevantes se dá através dos escores

Exemplo: (Mingoti,2007)

12 empresas, 3 variáveis: ganho bruto (X_1), ganho líquido (X_2) e patrimônio acumulado (X_3)

Empresa	Ganho bruto (X_1)	Ganho líquido (X_2)	Patrimônio (X_3)
<i>E1</i>	9893	564	17689
<i>E2</i>	8776	389	17359
<i>E3</i>	13572	1103	18597
<i>E4</i>	6455	743	8745
<i>E5</i>	5129	203	14397
<i>E6</i>	5432	215	3467
<i>E7</i>	3807	385	4679
<i>E8</i>	3423	187	6754
<i>E9</i>	3708	127	2275
<i>E10</i>	3294	297	6754
<i>E11</i>	5433	432	5589
<i>E12</i>	6287	451	8972

Primeiro Exemplo: (Mingoti,2007)

```
load <- function(pkg){  
  new.pkg <- pkg[!(pkg %in% installed.packages()[, "Package"])]  
  if (length(new.pkg))  
    install.packages(new.pkg, dependencies = TRUE)  
  sapply(pkg, require, character.only = TRUE)  
}
```

Pacotes utilizados nessa análise

```
packages = c("tidyverse", "factoextra", "psych", "gridExtra")  
load(packages)
```

tidyverse	factoextra	psych	gridExtra
TRUE	TRUE	TRUE	TRUE

```
dados <- read.table("https://raw.githubusercontent.com/tiagomartin/est014/  
dados %>%  
  str()
```

Primeiro Exemplo: (Mingoti,2007)

```
x_barra = dados %>%  
  colMeans()
```

```
x_barra
```

Granho_Bruto	Ganho_Liquido	Patrimonio
6267.4167	424.6667	9606.4167


```
S = dados %>%  
  var()
```

```
S
```

	Granho_Bruto	Ganho_Liquido	Patrimonio
Granho_Bruto	9550608.6	706121.06	14978232.5
Ganho_Liquido	706121.1	76269.52	933915.1
Patrimonio	14978232.5	933915.06	34408113.0

Primeiro Exemplo: (Mingoti,2007)

```
dados %>%  
  boxplot()
```



Primeiro Exemplo: (Mingoti,2007)

```
## Analise de Componentes Principais utilizando a matriz de covariancias (  
acp_S = prcomp(dados)  
  
## Proporcao da variacao explicada  
summary(acp_S)
```

Importance of components:

	PC1	PC2	PC3
Standard deviation	6440.0615	1.594e+03	145.23266
Proportion of Variance	0.9418	5.767e-02	0.00048
Cumulative Proportion	0.9418	9.995e-01	1.00000

```
## Loadings (cargas)  
acp_S$rotation
```

	PC1	PC2	PC3
Granho_Bruto	-0.42509725	-0.89970680	-0.09909593
Ganho_Liquido	-0.02766083	-0.09651661	0.99494694

Primeiro Exemplo: (Mingoti,2007)

$$Y_1 = 0,425 \times \text{GB} + 0,028 \times \text{GL} + 0,905 \times \text{PA} \implies 94,18\% \text{ da informação total de } \mathbf{x}$$

Primeiro Exemplo: (Mingoti,2007)

$$Y_1 = 0,425 \times \text{GB} + 0,028 \times \text{GL} + 0,905 \times \text{PA} \Rightarrow 94,18\% \text{ da informação total de } \mathbf{x}$$

Qual a variável mais importante para Y_1 ?

Patrimônio



Será?

Componentes Principais: variáveis padronizadas

- ▶ Padronização do vetor aleatório $\mathbf{x}$:

$$z = D^{-1}(\mathbf{x} - \mu)$$

Componentes Principais: variáveis padronizadas

- ▶ Padronização do vetor aleatório $\mathbf{x}$:

$$z = D^{-1}(\mathbf{x} - \mu)$$

- ▶ D : matriz diagonal de desvios-padrão

Componentes Principais: variáveis padronizadas

- ▶ Padronização do vetor aleatório $\mathbf{x}$:

$$\mathbf{z} = D^{-1}(\mathbf{x} - \boldsymbol{\mu})$$

- ▶ D : matriz diagonal de desvios-padrão

- ▶ Variável padronizada: $Z_i = \frac{X_i - \mu_i}{\sqrt{\sigma_{ii}}}$

Componentes Principais: variáveis padronizadas

- ▶ Padronização do vetor aleatório $\mathbf{x}$:

$$\mathbf{z} = D^{-1}(\mathbf{x} - \boldsymbol{\mu})$$

- ▶ D : matriz diagonal de desvios-padrão

- ▶ Variável padronizada: $Z_i = \frac{X_i - \mu_i}{\sqrt{\sigma_{ii}}}$

- ▶ Matriz de covariâncias de $\mathbf{z}$

$$\text{Cov}(\mathbf{z}) = D^{-1}\Sigma D^{-1} = P = \text{Cor}(\mathbf{x})$$

Componentes Principais: variáveis padronizadas

- ▶ Padronização do vetor aleatório $\mathbf{x}$:

$$\mathbf{z} = D^{-1}(\mathbf{x} - \boldsymbol{\mu})$$

- ▶ D : matriz diagonal de desvios-padrão

- ▶ Variável padronizada: $Z_i = \frac{X_i - \mu_i}{\sqrt{\sigma_{ii}}}$

- ▶ Matriz de covariâncias de $\mathbf{z}$

$$\text{Cov}(\mathbf{z}) = D^{-1}\Sigma D^{-1} = P = \text{Cor}(\mathbf{x})$$

- ▶ Componentes principais de $\mathbf{z}$: obtidas dos autovalores e autovetores de P

Componentes Principais: variáveis padronizadas

- A j -ésima componente principal da matriz P :

$$Y_j = e_j^t z = e_j^t D^{-1}(\mathbf{x} - \mu) = e_{j1}Z_1 + e_{j2}Z_2 + \cdots + e_{jp}Z_p$$

sendo e_j , o j -ésimo autovetor da matriz P , $j = 1, \cdots p$.

Componentes Principais: variáveis padronizadas

- ▶ A j -ésima componente principal da matriz P :

$$Y_j = e_j^t z = e_j^t D^{-1}(\mathbf{x} - \mu) = e_{j1}Z_1 + e_{j2}Z_2 + \cdots + e_{jp}Z_p$$

sendo e_j , o j -ésimo autovetor da matriz P , $j = 1, \dots, p$.

- ▶ Variância total de P

$$\sum_{j=1}^p \text{Var}(Y_j) = \sum_{j=1}^p \text{Var}(Z_j) = p$$

Componentes Principais: variáveis padronizadas

- Proporção da variância populacional padronizada devido à j -ésima componente

$$\frac{\text{Var}(Y_j)}{\text{Variância total de } z} = \frac{\lambda_j}{\text{tr}(P)} = \frac{\lambda_j}{p}$$

Componentes Principais: variáveis padronizadas

- ▶ Proporção da variância populacional padronizada devido à j -ésima componente

$$\frac{\text{Var}(Y_j)}{\text{Variância total de } z} = \frac{\lambda_j}{\text{tr}(P)} = \frac{\lambda_j}{p}$$

- ▶ Correlação entre componente Y_j e a variável padronizada Z_k :

$$\rho_{Y_j, Z_k} = e_{jk} \sqrt{\lambda_j}$$

Observações

- ▶ As componentes principais **não são invariantes à mudanças de escala**. Os resultados são **diferentes** quando se faz a análise utilizando a matriz de covariâncias e a matriz de correlações.

Observações

- ▶ As componentes principais **não são invariantes à mudanças de escala**. Os resultados são **diferentes** quando se faz a análise utilizando a matriz de covariâncias e a matriz de correlações.
- ▶ **As componentes obtidas a partir da matriz de covariâncias são influenciadas pelas variáveis de maior variância**. A matriz de correlações, em geral, é a melhor opção quando as **variâncias são muito heterogêneas**.

Observações

- ▶ As componentes principais **não são invariantes à mudanças de escala**. Os resultados são **diferentes** quando se faz a análise utilizando a matriz de covariâncias e a matriz de correlações.
- ▶ **As componentes obtidas a partir da matriz de covariâncias são influenciadas pelas variáveis de maior variância**. A matriz de correlações, em geral, é a melhor opção quando as **variâncias são muito heterogêneas**.
- ▶ Um valor **pequeno incomum** para o **último autovalor** da matriz de covariâncias (ou correlação) amostral pode indicar uma **dependência linear não detectada** no conjunto de dados.

Observações

- ▶ As componentes principais **não são invariantes à mudanças de escala**. Os resultados são **diferentes** quando se faz a análise utilizando a matriz de covariâncias e a matriz de correlações.
- ▶ **As componentes obtidas a partir da matriz de covariâncias são influenciadas pelas variáveis de maior variância**. A matriz de correlações, em geral, é a melhor opção quando as **variâncias são muito heterogêneas**.
- ▶ Um valor **pequeno incomum** para o **último autovalor** da matriz de covariâncias (ou correlação) amostral pode indicar uma **dependência linear não detectada** no conjunto de dados.
- ▶ Valores grandes de autovalores (e correspondentes autovetores) são importantes em uma análise.

Quantas componentes devem ser retidas?

- ▶ **Critério de Kaiser:** Trata-se de uma regra prática (heurística) para decidir quantas componentes principais manter em uma PCA extraída através da matriz de correlações. Ele diz:
Retenha apenas as componentes associadas a um autovalor maior que 1.
- ▶ $\lambda = 1 \rightarrow$ a componente explica tanta variabilidade quanto 1 variável original
- ▶ $\lambda > 1 \rightarrow$ explica mais variabilidade do que qualquer variável isolada
- ▶ $\lambda < 1 \rightarrow$ explica menos variabilidade do que uma única variável $\rightarrow$ então não “vale a pena”

Quantas componentes devem ser retidas?

- ▶ **Média dos autovalores:** É um critério alternativo quando a PCA é feita sobre **matriz de covariâncias**.
Se PCA foi feita na matriz de covariâncias, retenha PCs com autovalores maiores que a média dos autovalores.

Então, se uma componente tem autovalor:


$$\lambda_k > \frac{\sum_{j=1}^p \lambda_j}{p}$$

ela retém mais informação do que a variância média por dimensão do espaço original.

Quantas componentes devem ser retidas?


- ▶ **Screeplot:** É um gráfico que coloca, no eixo X, o número da componente principal e, no eixo Y, o autovalor (ou a variância explicada).
O ponto onde a curva deixa de cair abruptamente e começa a “horizontalizar” é onde você para de manter componentes.
- ▶ A ideia é identificar o “cotovelo” da curva.
 - ▶ antes do cotovelo: cada componente adiciona bastante variância
 - ▶ depois do cotovelo: os autovalores ficam “quase uma linha reta” → só ruído

Quantas componentes devem ser retidas?



Quantas componentes devem ser retidas?

- Reter o número de componentes principais que acumulem pelo menos certa porcentagem da variabilidade total dos dados, digamos 70%.




Quantas componentes devem ser retidas?

- ▶ **Parallel Analysis (Horn, 1965):** É o método moderno mais recomendado para decidir quantos componentes reter em PCA.
Compare seus autovalores reais com autovalores esperados ao acaso.

Quantas componentes devem ser retidas?

- ▶ O procedimento envolve:
 - ▶ Calcular os autovalores dos dados originais.
 - ▶ Gerar dados aleatórios com a mesma estrutura dos dados originais.
 - ▶ Calcular autovalores para os dados aleatórios, repetindo o processo muitas vezes para obter uma distribuição amostral.
 - ▶ Comparar os autovalores reais com os autovalores médios ou percentis (como o 95^º) dos dados simulados.
 - ▶ Reter os componentes cujos autovalores reais são maiores do que os autovalores aleatórios correspondentes.

Quantas componentes devem ser retidas?



Parallel analysis suggests that the number of factors = NA and the number

Quantas componentes devem ser retidas?

- ▶ **Interpretação desse gráfico**

- ▶ linha azul = autovalores reais dos seus dados
- ▶ linhas vermelha / pontilhada = autovalores esperados pelo acaso (parallel analysis)

Quantas componentes devem ser retidas?

- ▶ **Interpretação desse gráfico**

- ▶ linha azul = autovalores reais dos seus dados
- ▶ linhas vermelha / pontilhada = autovalores esperados pelo acaso (parallel analysis)

- ▶ **Regra:** retenha apenas os componentes cuja linha azul está acima da linha vermelha.

- ▶ Parallel Analysis (Horn) está dizendo: retenha 1 componente principal.

Interpretação das componentes principais

- ▶ Em geral, quando existe uma **alta correlação positiva** entre todas as variáveis, os **sinais associados às variáveis coincidem** na primeira componente principal.

Interpretação das componentes principais

- ▶ Em geral, quando existe uma **alta correlação positiva** entre todas as variáveis, os **sinais associados às variáveis coincidem** na primeira componente principal.
- ▶ Neste caso, a primeira componente principal pode ser interpretada como um **índice global**, calculado como uma média ponderada de todas as variáveis.

Interpretação das componentes principais


- ▶ Em geral, quando existe uma **alta correlação positiva** entre todas as variáveis, os **sinais associados às variáveis coincidem** na primeira componente principal.
- ▶ Neste caso, a primeira componente principal pode ser interpretada como um **índice global**, calculado como uma média ponderada de todas as variáveis.
- ▶ O restante das componentes, normalmente possuem **pesos negativos e positivos** e são interpretadas como um **contraste entre grupos de variáveis**.

Voltando ao Exemplo

12 empresas, 3 variáveis: ganho bruto (X_1), ganho líquido (X_2) e patrimônio acumulado (X_3)

Empresa	Ganho bruto (X_1)	Ganho líquido (X_2)	Patrimônio (X_3)
<i>E1</i>	9893	564	17689
<i>E2</i>	8776	389	17359
<i>E3</i>	13572	1103	18597
<i>E4</i>	6455	743	8745
<i>E5</i>	5129	203	14397
<i>E6</i>	5432	215	3467
<i>E7</i>	3807	385	4679
<i>E8</i>	3423	187	6754
<i>E9</i>	3708	127	2275
<i>E10</i>	3294	297	6754
<i>E11</i>	5433	432	5589
<i>E12</i>	6287	451	8972

Voltando ao Exemplo



Voltando ao Exemplo


```
dados %>%  
  scale(center=TRUE, scale=TRUE)
```

	Granho_Bruto	Ganho_Liquido	Patrimonio
E1	1.173173832	0.50452133	1.3779065
E2	0.811732638	-0.12914781	1.3216486
E3	2.363632341	2.45622228	1.5327010
E4	0.060698607	1.15267434	-0.1468530
E5	-0.368371244	-0.80264757	0.8166914
E6	-0.270325871	-0.75919598	-1.0466384
E7	-0.796146767	-0.14363167	-0.8400185
E8	-0.920402290	-0.86058304	-0.4862757
E9	-0.828181394	-1.07784103	-1.2498488
E10	-0.962144379	-0.46227672	-0.4862757
E11	-0.270002289	0.02655375	-0.6848831
E12	0.006336816	0.09535212	-0.1081544

```
attr(,"scaled:center")
```

Voltando ao Exemplo

```
dados %>%  
  scale(center=TRUE, scale=TRUE) %>%  
  boxplot()
```



Voltando ao Exemplo

```
## Analise de Componentes Principais utilizando a matriz de correlacoes (M  
acp_R = prcomp(dados, scale. = TRUE)  
  
## Proporcao da variacao explicada  
summary(acp_R)
```

Importance of components:

	PC1	PC2	PC3
Standard deviation	1.5788	0.6508	0.28978
Proportion of Variance	0.8308	0.1412	0.02799
Cumulative Proportion	0.8308	0.9720	1.00000

```
## Loadings (cargas)  
acp_R$rotation
```

	PC1	PC2	PC3
Granho_Bruto	-0.6167027	0.001267206	0.7871952
Ganho_Liquido	-0.5567945	0.706196936	-0.4373395

Voltando ao Exemplo

```
## Escores das componentes principais
```

```
Yr = acp_R$x
```

```
Yr %>% head()
```

	PC1	PC2	PC3
E1	1.7711764	0.6177995	-0.1037449
E2	1.1641454	1.0259213	-0.1208101
E3	3.6781699	-0.6523976	-0.1200063
E4	0.5975165	-0.9180660	0.3924755
E5	-0.2196218	1.1455233	0.2940545
E6	-1.1718486	-0.2045506	-0.5743139

```
## Matriz de correlacoes entre variaveis originais e componentes principais
```


```
Ryx_R = cor(dados,Yr)
```

```
Ryx_R
```

	PC1	PC2	PC3
Granho_Bruto	0.9736351	-0.0008246563	-0.2281098

Voltando ao Exemplo

```
fa.parallel(dados %>% scale(center=TRUE, scale=TRUE), fa="pc", n.iter=1000)
```



Voltando ao Exemplo

$$Z_{GB} = \frac{\text{Ganho Bruto} - \overline{\text{Ganho Bruto}}}{s_{\text{Ganho Bruto}}}$$

$$Z_{GL} = \frac{\text{Ganho Líquido} - \overline{\text{Ganho Líquido}}}{s_{\text{Ganho Líquido}}}$$

$$Z_{PA} = \frac{\text{Patrimônio} - \overline{\text{Patrimônio}}}{s_{\text{Patrimônio}}}$$

Voltando ao Exemplo

$$Y_1 = 0,617 \times Z_{GB} + 0,557 \times Z_{GL} + 0,556 \times Z_{PA} \implies 83,08\% \text{ da informação total de } z$$

Voltando ao Exemplo

$$Y_1 = 0,617 \times Z_{GB} + 0,557 \times Z_{GL} + 0,556 \times Z_{PA} \Rightarrow 83,08\% \text{ da informação total de } z$$

- **Interpretação:** É basicamente um índice de desempenho global da empresa. O coeficiente de maior grandeza numérica desta componente é relativo a ganho bruto enquanto que os demais coeficientes são aproximadamente iguais. Quanto maior os valores de ganhos brutos e líquido e patrimônio da empresa, maior será o valor numérico da componente. Além disso, todas as três variáveis possui alta correlação com essa componente, indicando serem importantes na composição da mesma.

Voltando ao Exemplo

$$Y_2 = -0,001 \times Z_{GB} - 0,706 \times Z_{GL} + 0,708 \times Z_{PA} \implies 14,12\% \text{ da informação total de } z$$


Voltando ao Exemplo

$$Y_2 = -0,001 \times Z_{GB} - 0,706 \times Z_{GL} + 0,708 \times Z_{PA} \Rightarrow 14,12\% \text{ da informação total de } z$$

- **Interpretação:** É uma comparação entre as variáveis ganho líquido e patrimônio, sendo que essas duas variáveis possuem igual importância na composição da mesma. Valores próximos de zero dessa componente indicam empresas com um certo equilíbrio entre ganho líquido e patrimônio acumulado no período.

Voltando ao Exemplo

```
fviz_pca_biplot(acp_R, repel = TRUE,  
  col.var = "#2E9FDF", # Variables color  
  col.ind = "#696969"  # Individuals color  
)
```



Voltando ao Exemplo

Interpretação do biplot

- ▶ As setas indicam em que direção a variável aumenta. os indivíduos que estão posicionados no sentido da seta são os que têm valores maiores naquela variável.

Voltando ao Exemplo

Interpretação do biplot

- ▶ As setas indicam em que direção a variável aumenta. os indivíduos que estão posicionados no sentido da seta são os que têm valores maiores naquela variável.
- ▶ **Ângulo entre a seta (variável) e o eixo PC1:** O cosseno do ângulo entre a variável e a PC é exatamente o **loading**.

$$\cos(\theta_j, PC_i) = \text{loading}_{X_j, PC_i}$$

Voltando ao Exemplo

então:

- ▶ se a seta está quase colada no eixo PC_i
 - ▶ loading próximo de $+1 \rightarrow$ variável altamente alinhada com a componente
 - ▶ é variável que define o componente principal
- ▶ se a seta faz um ângulo grande (perto de 90°) com PC_i
 - ▶ loading $\approx 0 \rightarrow$ essa variável não contribui para a componente
- ▶ se a seta aponta para o lado oposto da PC_i (180°)
 - ▶ loading $\approx -1 \rightarrow$ variável altamente alinhada negativamente

Voltando ao Exemplo

- ▶ **Observação:** Quando a PCA é feita na **matriz de correlações**, os loadings são exatamente as correlações entre as variáveis originais e as componentes principais. Quando usamos **matriz de covariâncias**, os loadings refletem contribuição em variância e o cosseno do ângulo não corresponde numericamente à correlação.

Voltando ao Exemplo

- ▶ **PC1 (Dim1 = 83.1%):** Praticamente toda a informação relevante está aqui. *PC1 representa um eixo geral de nível financeiro / escala econômica. Quanto maior Patrimônio / Ganho Bruto / Ganho Líquido → mais à direita o indivíduo aparece.*
- ▶ Todas variáveis apontam para a direita, e com ângulos semelhantes → altíssima correlação entre elas

Voltando ao Exemplo


- ▶ Quem está mais pra direita (E1, E2, E3) → são aqueles com valores altos nessas variáveis
- ▶ Quem está mais pra esquerda (E8, E9, E10...) → são os com valores baixos
- ▶ A empresa E12 posiciona-se muito próxima à origem do plano principal, indicando um perfil mediano em todas as variáveis financeiras consideradas.
 - ▶ Ela não apresenta características extremas nem para valores altos, nem para valores baixos, sendo portanto uma empresa altamente representativa do centro da distribuição.

Voltando ao Exemplo

- ▶ Quem está mais pra direita (E1, E2, E3) → são aqueles com valores altos nessas variáveis
- ▶ Quem está mais pra esquerda (E8, E9, E10...) → são os com valores baixos
- ▶ A empresa E12 posiciona-se muito próxima à origem do plano principal, indicando um perfil mediano em todas as variáveis financeiras consideradas.
 - ▶ Ela não apresenta características extremas nem para valores altos, nem para valores baixos, sendo portanto uma empresa altamente representativa do centro da distribuição.
- ▶ **PC2 (Dim2 = 14.1%)**: quase não traz informação nova → setas não sobem muito, elas estão quase horizontais
 - ▶ não existe uma segunda dimensão “conceitual” forte

Voltando a Exemplo

```
# Contribuições das variáveis para a PC1  
fviz_contrib(acp_R, choice = "var", axes = 1)
```



Voltando ao Exemplo


- ▶ Esse gráfico mostra o quanto cada variável explica/contribui para a formação do primeiro componente principal.
 - ▶ Ganho Bruto contribuiu um pouco mais
 - ▶ Ganho Liquido e Patrimonio contribuem praticamente igual e muito próximo

Voltando ao Exemplo

- ▶ Esse gráfico mostra o quanto cada variável explica/contribui para a formação do primeiro componente principal.
 - ▶ Ganho Bruto contribuiu um pouco mais
 - ▶ Ganho Liquido e Patrimonio contribuem praticamente igual e muito próximo
- ▶ A linha vermelha tracejada é a contribuição média esperada (se todas contribuíssem igual).
 - ▶ Como temos 3 variáveis $\rightarrow$ contribuição média = $100\%/3 \approx 33.33\%$

Voltando ao Exemplo

```
fviz_contrib(acp_R, choice = "ind", axes = 1:2)
```



Voltando ao Exemplo

- ▶ Esse gráfico mostra quais indivíduos contribuem mais para definir o plano principal da PC, isto é, quais observações estão orientando a direção das componentes principais.

Voltando ao Exemplo

- ▶ Esse gráfico mostra quais indivíduos contribuem mais para definir o plano principal da PC, isto é, quais observações estão orientando a direção das componentes principais.
- ▶ A empresa E3 é a maior influenciadora da PCA: sua contribuição para o plano principal é muito superior à média (linha vermelha), indicando que ela é um caso extremo na direção da primeira componente. Esse ponto está orientando de forma dominante a estrutura da análise.