

Análise Discriminante

O Problema da classificação e discriminação

- ▶ Dois tipos de problemas recorrentes em análise de dados, e que podem ser abordados por técnicas multivariadas, são **discriminação** e **classificação**.

O Problema da classificação e discriminação

- ▶ Dois tipos de problemas recorrentes em análise de dados, e que podem ser abordados por técnicas multivariadas, são **discriminação** e **classificação**.
- ▶ Em um problema de **discriminação**, o objetivo é aplicar e avaliar a contribuição de p variáveis na discriminação (separação) de k grupos **pré-definidos**;

O Problema da classificação e discriminação

- ▶ Dois tipos de problemas recorrentes em análise de dados, e que podem ser abordados por técnicas multivariadas, são **discriminação** e **classificação**.
- ▶ Em um problema de **discriminação**, o objetivo é aplicar e avaliar a contribuição de p variáveis na discriminação (separação) de k grupos **pré-definidos**;
- ▶ Em um problema de **classificação**, o objetivo é construir uma regra, baseada em p variáveis e n indivíduos, que permita classificar novos indivíduos em um de k grupos **pré-definidos**.

Discriminação em dois grupos

- Considere que desejamos discriminar indivíduos de duas populações π_1 e π_2 com base em p variáveis avaliadas $x = [X_1, X_2, \dots, X_p]^t$.

Discriminação em dois grupos

- ▶ Considere que desejamos discriminar indivíduos de duas populações π_1 e π_2 com base em p variáveis avaliadas $x = [X_1, X_2, \dots, X_p]^t$.
- ▶ Considere ainda conhecidas μ_1 , μ_2 , Σ_1 e Σ_2 .

Discriminação em dois grupos

- ▶ Considere que desejamos discriminar indivíduos de duas populações π_1 e π_2 com base em p variáveis avaliadas $x = [X_1, X_2, \dots, X_p]^t$.
- ▶ Considere ainda conhecidas μ_1 , μ_2 , Σ_1 e Σ_2 .
- ▶ Sejam $f_1(x)$ e $f_2(x)$ as funções (densidade) de probabilidade de x em π_1 e π_2 .


Discriminação em dois grupos

- ▶ Considere que desejamos discriminar indivíduos de duas populações π_1 e π_2 com base em p variáveis avaliadas $x = [X_1, X_2, \dots, X_p]^t$.
- ▶ Considere ainda conhecidas μ_1 , μ_2 , Σ_1 e Σ_2 .
- ▶ Sejam $f_1(x)$ e $f_2(x)$ as funções (densidade) de probabilidade de x em π_1 e π_2 .
- ▶ Seja Ω o espaço amostral (conjunto de resultados possíveis para x).

Classificação em dois grupos - Regras de classificação

- ▶ Vamos considerar uma partição de Ω em dois conjuntos R_1 e R_2 , $(R_1 \cup R_2 = \Omega; R_1 \cap R_2 = \emptyset)$, tal que:
 - ▶ Todo indivíduo tal que $x \in R_1$ seja classificado como pertencente a π_1 ;
 - ▶ Todo indivíduo tal que $x \in \Omega - R_1 = R_2$ seja classificado como pertencente a π_2 .

Classificação em dois grupos - Ilustração



Classificação em dois grupos - Probabilidades de má-classificação

Com base no que foi apresentado, temos as seguintes probabilidades:


- ▶ $P(2|1)$: Probabilidade de classificar um indivíduo em π_2 dado que ele pertence a π_1 :

$$P(2|1) = P(x \in R_2 | \pi_1) = \int_{R_2} f_1(x) dx$$

- ▶ $P(1|2)$: Probabilidade de classificar um indivíduo em π_1 dado que ele pertence a π_2 :

$$P(1|2) = P(x \in R_1 | \pi_2) = \int_{R_1} f_2(x) dx$$

Classificação em dois grupos - Ilustração



Classificação em dois grupos - Incorporando probabilidades a priori

Vamos assumir probabilidades a priori $p_1 = P(\pi_1)$ e $p_2 = P(\pi_2)$ de um indivíduo pertencer a π_1 e π_2 , respectivamente ($p_1 + p_2 = 1$). Então:

- Probabilidade de um indivíduo ser classificado na população 1 (C_1) e de fato pertencer a π_1 :

$$P(C_1 \cap \pi_1) = P(C_1|\pi_1)P(\pi_1) = P(1|1)p_1$$

- Probabilidade de um indivíduo ser incorretamente classificado na população π_1 :

$$P(C_1 \cap \pi_2) = P(C_1|\pi_2)P(\pi_2) = P(1|2)p_2$$

Classificação em dois grupos - Incorporando probabilidades a priori

- Probabilidade de um indivíduo ser classificado na população 2 (C_2) e de fato pertencer a π_2 :

$$P(C_2 \cap \pi_2) = P(C_2|\pi_2)P(\pi_2) = P(2|2)p_2$$

- Probabilidade de um indivíduo ser incorretamente classificado na população π_2 :

$$P(C_2 \cap \pi_1) = P(C_2|\pi_1)P(\pi_1) = P(2|1)p_1$$

Classificação em dois grupos - Incorporando custos de má-classificação

Agora vamos incorporar custos de má-classificação:

- ▶ Seja $c(1|2)$ o custo de classificar um indivíduo pertencente a π_2 como pertencente a π_1 ;

Classificação em dois grupos - Incorporando custos de má-classificação

Agora vamos incorporar custos de má-classificação:

- ▶ Seja $c(1|2)$ o custo de classificar um indivíduo pertencente a π_2 como pertencente a π_1 ;
- ▶ Seja $c(2|1)$ o custo de classificar um indivíduo pertencente a π_1 como pertencente a π_2 ;

Classificação em dois grupos - Incorporando custos de má-classificação

Agora vamos incorporar custos de má-classificação:

- ▶ Seja $c(1|2)$ o custo de classificar um indivíduo pertencente a π_2 como pertencente a π_1 ;
- ▶ Seja $c(2|1)$ o custo de classificar um indivíduo pertencente a π_1 como pertencente a π_2 ;

Naturalmente, consideramos $c(1|1) = c(2|2) = 0$.

Classificação em dois grupos - Custo esperado de má-classificação (ECM)

Diferentes critérios podem ser utilizados para fins de determinar a regra de classificação. Um deles é a minimização do **custo esperado de má-classificação**.

- ▶ Para qualquer regra de classificação, o custo esperado de má-classificação (ECM) fica dado por:

$$ECM = c(2|1)P(2|1)p_1 + c(1|2)P(1|2)p_2$$

- ▶ Assim, a melhor regra de classificação, baseada nesse critério, seria aquela que minimizasse ECM .

Classificação em dois grupos - Regras de classificação para mínimo (ECM)

As regiões R_1 e R_2 , responsáveis por alocar qualquer observação x a π_1 ou π_2 (respectivamente), **tal que ECM seja mínimo**, são dadas por:

$$R_1 := \frac{f_1(x)}{f_2(x)} \geq \left(\frac{c(1|2)}{c(2|1)} \right) \left(\frac{p_2}{p_1} \right)$$

ou, de forma equivalente, $p_1 c(2|1) f_1(x) \geq p_2 c(1|2) f_2(x)$;

$$R_2 := \frac{f_1(x)}{f_2(x)} < \left(\frac{c(1|2)}{c(2|1)} \right) \left(\frac{p_2}{p_1} \right)$$

ou, de forma equivalente, $p_1 c(2|1) f_1(x) < p_2 c(1|2) f_2(x)$.

Classificação em dois grupos - casos particulares

- $p_1 = p_2$ (probabilidades a priori iguais):

$$R_1 := \frac{f_1(x)}{f_2(x)} \geq \left(\frac{c(1|2)}{c(2|1)} \right) \quad R_2 := \frac{f_1(x)}{f_2(x)} < \left(\frac{c(1|2)}{c(2|1)} \right)$$

- $c(1|2) = c(2|1)$ (custos de má-classificação iguais):

$$R_1 := \frac{f_1(x)}{f_2(x)} \geq \left(\frac{p_2}{p_1} \right) \quad R_2 := \frac{f_1(x)}{f_2(x)} < \left(\frac{p_2}{p_1} \right)$$

Classificação em dois grupos - casos particulares

► $p_1 = p_2$ e $c(1|2) = c(2|1)$:

$$R_1 := \frac{f_1(x)}{f_2(x)} \geq 1 \quad R_2 := \frac{f_1(x)}{f_2(x)} < 1$$

Classificação em dois grupos - Classificação pelo Teorema de Bayes

Usando o teorema de Bayes, podemos alocar uma nova observação x_0 à população com maior probabilidade a posteriori:

$$P(\pi_1|x_0) = \frac{p_1 f_1(x_0)}{p_1 f_1(x_0) + p_2 f_2(x_0)};$$

$$P(\pi_2|x_0) = 1 - P(\pi_1|x_0)$$

Classificação em duas população normais

1º caso: as populações possuem variância comum

► Suponha agora que x segue a distribuição normal multivariada. Assim, temos que

$$f_i(x) = (2\pi)^{-p/2} |\Sigma|^{-1/2} \exp \left\{ -\frac{1}{2} (x - \mu_i)^t \Sigma^{-1} (x - \mu_i) \right\}$$

para $i = 1, 2$ em que μ_i é o vetor de médias da i -ésima população e Σ é a matriz de covariâncias positiva definida comum às duas populações.

Classificação em duas população normais

1º caso: as populações possuem variância comum

- ▶ De acordo com a regra do mínimo custo esperado de má-classificação (ECM), devemos classificar x em π_1 se

$$\frac{f_1(x)}{f_2(x)} \geq \left(\frac{c(1|2)}{c(2|1)} \right) \left(\frac{p_2}{p_1} \right)$$

- ▶ Se substituirmos as densidades $f_1(x)$ e $f_2(x)$ pela densidade normal correspondente teremos:

$$\exp \left\{ -\frac{1}{2} (x - \mu_1)^t \Sigma^{-1} (x - \mu_1) + \frac{1}{2} (x - \mu_2)^t \Sigma^{-1} (x - \mu_2) \right\} \geq \left(\frac{c(1|2)}{c(2|1)} \right) \left(\frac{p_2}{p_1} \right)$$

Classificação em duas população normais

1º caso: as populações possuem variância comum

► Que, depois de algum algebrismo, torna-se

$$\exp \left\{ (\mu_1 - \mu_2)^t \Sigma^{-1} x - \frac{1}{2} (\mu_1 - \mu_2)^t \Sigma^{-1} (\mu_1 + \mu_2) \right\} \geq \left(\frac{c(1|2)}{c(2|1)} \right) \left(\frac{p_2}{p_1} \right)$$

► Como ambos os termos são positivos, podemos tomar o logaritmo preservando a ordem da desigualdade. Assim, devemos alocar x em π_1 se

$$(\mu_1 - \mu_2)^t \Sigma^{-1} x - \frac{1}{2} (\mu_1 - \mu_2)^t \Sigma^{-1} (\mu_1 + \mu_2) \geq \ln \left\{ \left(\frac{c(1|2)}{c(2|1)} \right) \left(\frac{p_2}{p_1} \right) \right\}$$

e em π_2 , caso contrário.

Classificação em duas população normais

Para dados amostrais

Se considerarmos n_1 observações p -variadas $X_{11}, X_{12}, \dots, X_{1n_1}$ amostradas da população π_1 e n_2 , $X_{21}, X_{22}, \dots, X_{2n_2}$ amostradas da população π_2 , com $n_1 + n_2 - 2 \geq p$, então a regra de alocação estimada que minimiza o custo médio de má-classificação é dada por: alocar x na população π_1 se

$$(\bar{x}_1 - \bar{x}_2)^t S_c^{-1} x - \frac{1}{2}(\bar{x}_1 - \bar{x}_2)^t S_c^{-1} (\bar{x}_1 + \bar{x}_2) \geq \ln \left\{ \left(\frac{c(1|2)}{c(2|1)} \right) \left(\frac{p_2}{p_1} \right) \right\}$$

em que

$$S_c = \frac{(n_1 - 1)S_1 + (n_2 - 1)S_2}{n_1 + n_2 - 2}$$

Classificação em duas população normais

2º caso: as populações não possuem variância comum

Sob a suposição de homogeneidade das matrizes de covariâncias, verificamos que as regras de classificação originadas foram simples e lineares.

- Se considerarmos a situação geral em que $f_1(x)$ e $f_2(x)$ são modelos normais multivariados com parâmetros μ_i e Σ_i , $i = 1, 2$, sendo $\Sigma_1 \neq \Sigma_2$, devemos classificar x em π_1 , se

$$-\frac{1}{2}x^t(\Sigma_1 - \Sigma_2)x + (\mu_1^t\Sigma_1^{-1} - \mu_2^t\Sigma_2^{-1})x - \delta \geq \ln \left\{ \left(\frac{c(1|2)}{c(2|1)} \right) \left(\frac{p_2}{p_1} \right) \right\}$$

e em π_2 , caso contrário.

Classificação em duas população normais

2º caso: as populações não possuem variância comum

► Sendo,

$$\delta = \frac{1}{2} \ln \left(\frac{|\Sigma_1|}{|\Sigma_2|} \right) + \frac{1}{2} (\mu_1^t \Sigma_1^{-1} \mu_1 - \mu_2^t \Sigma_2^{-1} \mu_2)$$

► Ao contrário do caso homocedástico, as regiões de classificação são definidas por funções discriminantes quadráticas de x .

Classificação em duas população normais

Para dados amostrais

- Podemos obter uma regra estimada substituindo os parâmetros μ_i e Σ_i , pelos respectivos estimadores $\bar{x}_i$ e S_i , $i = 1, 2$. Assim, devemos alocar x na população π_1 se

$$-\frac{1}{2}x^t(S_1 - S_2)x + (\bar{x}_1^t S_1^{-1} - \bar{x}_2^t S_2^{-1})x - \hat{\delta} \geq \ln \left\{ \left(\frac{c(1|2)}{c(2|1)} \right) \left(\frac{p_2}{p_1} \right) \right\}$$

e em π_2 , caso contrário, sendo

$$\hat{\delta} = \frac{1}{2} \ln \left(\frac{|S_1|}{|S_2|} \right) + \frac{1}{2} (\bar{x}_1^t S_1^{-1} \bar{x}_1 - \bar{x}_2^t S_2^{-1} \bar{x}_2)$$

Discriminação em duas populações

A função discriminante linear de Fisher

- ▶ Suposição de linearidade: **Homocedasticidade!**

$$\Sigma_1 = \Sigma_2 = \Sigma$$

- ▶ Matriz de variância comum
- ▶ Não pressupõe normalidade multivariada dos dados!

Discriminação em duas populações

A função discriminante linear de Fisher

- ▶ Baseada na **distância de Mahalanobis** entre o indivíduo desconhecido x_0 e as médias das populações:

$$d^2(x, \mu_i) = (x - \mu_i)^t \Sigma^{-1} (x - \mu_i), \quad i = 1, 2$$

- ▶ Intuitivamente, para um novo indivíduo x_0 , se $d^2(x_0, \mu_1) < d^2(x_0, \mu_2)$, classificamos x_0 em π_1 . Caso contrário, classificamos x_0 em π_2

Discriminação em duas populações

A função discriminante linear de Fisher

- Expressando essa regra como uma função discriminante:

$$\begin{aligned}d^2(x, \mu_2) - d^2(x, \mu_1) &= (x - \mu_2)^t \Sigma^{-1} (x - \mu_2) - (x - \mu_1)^t \Sigma^{-1} (x - \mu_1) \\ &= (\mu_2 - \mu_1)^t \Sigma^{-1} (\mu_2 + \mu_1) + 2x^t \Sigma^{-1} (\mu_1 - \mu_2)\end{aligned}$$

- A expressão acima pode ser reescrita como:

$$L(x) = \left[x - \frac{1}{2}(\mu_1 + \mu_2) \right]^t \Sigma^{-1} (\mu_1 - \mu_2)$$

Discriminação em duas populações

A função discriminante linear de Fisher

► Ou ainda...

$$L(x) = (\mu_1 - \mu_2)^t \Sigma^{-1} x - \frac{1}{2} (\mu_1 - \mu_2)^t \Sigma^{-1} (\mu_1 + \mu_2)$$

► O primeiro termo

$$D(x) = (\mu_1 - \mu_2)^t \Sigma^{-1} x$$

é chamado de **função discriminante linear de Fisher**.

Discriminação em duas populações

A função discriminante linear de Fisher

► Observe o segundo termo de

$$L(x) = (\mu_1 - \mu_2)^t \Sigma^{-1} x - \frac{1}{2} (\mu_1 - \mu_2)^t \Sigma^{-1} (\mu_1 + \mu_2)$$

após algum algebrismo,

$$\begin{aligned} m &= \frac{1}{2} (\mu_1 - \mu_2)^t \Sigma^{-1} (\mu_1 + \mu_2) \\ &= \frac{1}{2} [(\mu_1 - \mu_2)^t \Sigma^{-1} \mu_1 + (\mu_1 - \mu_2)^t \Sigma^{-1} \mu_2] \\ &= \frac{1}{2} [D(\mu_1) + D(\mu_2)] \end{aligned}$$

Discriminação em duas populações

A função discriminante linear de Fisher

- ▶ A regra de classificação fica: Se $D(x_0) > m$, classificamos x_0 em π_1 . Caso contrário, classificamos x_0 em π_2 .
- ▶ É interessante observar que $(\mu_1 - \mu_2)^t \Sigma^{-1} x = b^t x$, onde $b^t = (\mu_1 - \mu_2)^t \Sigma^{-1}$ é um vetor de dimensão $1 \times p$.
- ▶ Desse modo, a **função discriminante de Fisher** tem a forma:

$$(\mu_1 - \mu_2)^t \Sigma^{-1} x = b^t x = b_1 x_1 + b_2 x_2 + \cdots + b_p x_p$$

Discriminação em duas populações

Para dados amostrais

$$\widehat{D}(x) = (\bar{x}_1 - \bar{x}_2)^t S_c^{-1} x$$

$$\widehat{m} = \frac{1}{2} [\widehat{D}(\bar{x}_1) + \widehat{D}(\bar{x}_2)]$$

$$S_c = \frac{(n_1 - 1)S_1 + (n_2 - 1)S_2}{n_1 + n_2 - 2}$$

Probabilidade de classificação incorreta

Estimação das probabilidades de classificação incorreta

► Seja a seguinte tabela:

Frequências dos erros de classificação

População de origem	Classe 1	Classe 2	Total
1	n_{11}	n_{12}	n_1
2	n_{21}	n_{22}	n_2

n_{ij} : é o número de elementos de i classificados em j

Probabilidade de classificação incorreta

Estimação das probabilidades de classificação incorreta

- ▶ Com base nessas quantidades, podemos estimar as probabilidades de ocorrência dos erros 1 e 2 por:

$$\hat{p}(2|1) = \frac{n_{12}}{n_1} \quad \text{e} \quad \hat{p}(1|2) = \frac{n_{21}}{n_2}$$

- ▶ Além disso, podemos estimar a probabilidade global de acerto da função discriminante por:

$$\hat{p}(acerto) = \frac{n_{11} + n_{22}}{n_1 + n_2}$$

Probabilidade de classificação incorreta

Estimação das probabilidades de classificação incorreta

- Podemos também, estimar a taxa de erro aparente (TEA):

$$TEA = \frac{n_{12} + n_{21}}{n_1 + n_2}$$

Probabilidade de classificação incorreta

- ▶ Três métodos de determinação dessas probabilidades:
 - ▶ **Método da ressubstituição:** os mesmos dados são utilizados para estimar e validar a função discriminante.
 - ▶ **Método da ressubstituição com divisão amostral:** os dados são divididos em duas subamostras - treinamento: estima a fd, validação: estima as probabilidades de erro.
 - ▶ **Método da validação cruzada:** a cada iteração é omitida uma observação e a fd é estimada a partir das demais. A observação omitida é utilizada para estimar as probabilidades de erro.

Classificação em k grupos

- ▶ Sejam $f_1(x), f_2(x), \dots, f_k(x)$ as distribuições do vetor aleatório x em cada uma de k populações, $\pi_1, \pi_2, \dots, \pi_k$;

Classificação em k grupos

- ▶ Sejam $f_1(x), f_2(x), \dots, f_k(x)$ as distribuições do vetor aleatório x em cada uma de k populações, $\pi_1, \pi_2, \dots, \pi_k$;
- ▶ Sejam $p_1, p_2, \dots, p_k$ as probabilidades a priori e $c(i|j)$, $i, j = 1, 2, \dots, k$, os custos de má-classificação.

Classificação em k grupos

- ▶ Sejam $f_1(x), f_2(x), \dots, f_k(x)$ as distribuições do vetor aleatório x em cada uma de k populações, $\pi_1, \pi_2, \dots, \pi_k$;
- ▶ Sejam $p_1, p_2, \dots, p_k$ as probabilidades a priori e $c(i|j)$, $i, j = 1, 2, \dots, k$, os custos de má-classificação.
- ▶ Seja R_i o conjunto dos x 's classificados como π_i , $i = 1, 2, \dots, k$, e

$$P(j|i) = \int_{R_j} f_i(x) dx \quad i, j = 1, 2, \dots, k$$

Classificação em k grupos

- Custo esperado de má classificação:

$$ECM = p_1 ECM(1) + p_2 ECM(2) + \dots + p_k ECM(k)$$

em que,

$$ECM(i) = P(1|i)c(1|i) + P(2|i)c(2|i) + \dots + P(k|i)c(k|i), \quad i = 1, 2, \dots, k$$

Classificação em k grupos

- Custo esperado de má classificação:

$$ECM = p_1 ECM(1) + p_2 ECM(2) + \dots + p_k ECM(k)$$

em que,

$$ECM(i) = P(1|i)c(1|i) + P(2|i)c(2|i) + \dots + P(k|i)c(k|i), \quad i = 1, 2, \dots, k$$

- A regra de classificação **tal que ECM seja mínimo** consiste em classificar uma observação x no grupo j tal que:

$$\sum_{i=1, i \neq j}^k p_i f_i(x) c(j|i), \quad \text{seja mínimo.}$$

Classificação em k grupos

- ▶ Assim, deve-se classificar x em π_j caso a média dos custos de classificações incorretas nas demais populações seja mínima.

Classificação em k grupos

- ▶ Assim, deve-se classificar x em π_j caso a média dos custos de classificações incorretas nas demais populações seja mínima.
- ▶ Observe que para $k = 2$ populações, essa regra de classificação fica simplificada, sendo dada pela regra de classificação para duas populações apresentada anteriormente.

Classificação em mais de duas população normais

- Suponha agora que x segue a distribuição normal multivariada. Assim, temos que

$$f_i(x) = (2\pi)^{-p/2} |\Sigma_i|^{-1/2} \exp \left\{ -\frac{1}{2} (x - \mu_i)^t \Sigma_i^{-1} (x - \mu_i) \right\}$$

para $i = 1, 2, \dots, k$ em que μ_i é o vetor de médias da i -ésima população e Σ_i é a matriz de covariâncias positiva definida da i -ésima população.

Classificação em mais de duas população normais

- Considerando que estes parâmetros são conhecidos, então pela regra de classificação de mínima probabilidade total de classificação incorreta, devemos classificar x na população π_i se

$$\begin{aligned}\ln [p_i f_i(x)] &= \ln (p_i) - \frac{p}{2} \ln (2\pi) - \frac{1}{2} \ln (|\Sigma_i|) - \frac{1}{2} (x - \mu_i)^t \Sigma_i^{-1} (x - \mu_i) \\ &= \max_j \ln [p_j f_j(x)]\end{aligned}$$

- Alocamos a observação x à população que maximiza $\ln [p_j f_j(x)]$, em relação a todos os valores de j , $j = 1, 2, \dots, k$.

Classificação em mais de duas população normais

- ▶ O termo $\frac{p}{2} \ln(2\pi)$ é constante para todas as k populações e pode ser ignorado.

Classificação em mais de duas população normais

- ▶ O termo $\frac{p}{2} \ln(2\pi)$ é constante para todas as k populações e pode ser ignorado.
- ▶ O termo resultante é denominado de escore quadrático de discriminação e para a i -ésima população é dado por

$$d_i^Q(x) = -\frac{1}{2} \ln(|\Sigma_i|) - \frac{1}{2} (x - \mu_i)^t \Sigma_i^{-1} (x - \mu_i) + \ln(p_i)$$

Classificação em mais de duas população normais

- Utilizando o escore quadrático $d_i^Q(x)$ de discriminação, podemos simplificar a regra de classificação. Classificamos x em π_i se

$$d_i^Q(x) = \max_j \left[d_j^Q(x) \right]$$

para $j = 1, 2, \dots, k$.

Classificação em mais de duas população normais

Para dados amostrais

- ▶ Podemos obter uma regra estimada substituindo os parâmetros μ_i e Σ_i , pelos respectivos estimadores $\bar{x}_i$ e S_i , $i = 1, 2, \dots, k$.
- ▶ O estimador da função quadrática $d_i^Q(x)$ é representado por $Q_i(x)$ e é dado por

$$Q_i(x) = -\frac{1}{2} \ln(|S_i|) - \frac{1}{2} (x - \bar{x}_i)^t S_i^{-1} (x - \bar{x}_i) + \ln(p_i)$$

para $i = 1, 2, \dots, k$ e, pela regra estimada de mínima probabilidade total de classificação incorreta, devemos classificar a observação x em π_i se

$$Q_i(x) = \max_j [Q_j(x)] , \quad j = 1, 2, \dots, k$$

Classificação em mais de duas população normais

► No caso particular em que $\Sigma_1 = \Sigma_2 = \dots = \Sigma_k = \Sigma$:

$$d_i^Q(x) = -\frac{1}{2} \ln(|\Sigma|) - \frac{1}{2} (x - \mu_i)^t \Sigma^{-1} (x - \mu_i) + \ln(p_i)$$

para $i = 1, 2, \dots, k$.

Classificação em mais de duas população normais

- ▶ No caso particular em que $\Sigma_1 = \Sigma_2 = \dots = \Sigma_k = \Sigma$:

$$d_i^Q(x) = -\frac{1}{2} \ln(|\Sigma|) - \frac{1}{2} (x - \mu_i)^t \Sigma^{-1} (x - \mu_i) + \ln(p_i)$$

para $i = 1, 2, \dots, k$.

- ▶ Se ignorarmos os termos constantes a todas as k populações, obtemos o escore discriminante linear $d_i(x)$

$$d_i(x) = \mu_i^t \Sigma^{-1} x - \frac{1}{2} \mu_i^t \Sigma^{-1} \mu_i + \ln(p_i)$$

para $i = 1, 2, \dots, k$.

Classificação em mais de duas população normais

- Portanto, devemos classificar x em π_i se

$$d_i(x) = \max_j [d_j(x)] , \quad j = 1, 2, \dots, k$$

Classificação em mais de duas população normais

Para dados amostrais

- Uma estimativa dessa regra de classificação é obtida substituindo os parâmetros pelas estimativas.

$$\hat{d}_i(x) = \bar{x}_i^t S_c^{-1} x - \frac{1}{2} \bar{x}_i^t S_c^{-1} \bar{x}_i + \ln(p_i)$$

sendo

$$S_c = \frac{(n_1 - 1)S_1 + (n_2 - 1)S_2 + \cdots + (n_k - 1)S_k}{n_1 + n_2 + \cdots + n_k - k}$$

para $i = 1, 2, \dots, k$.

Classificação em mais de duas população normais

Para dados amostrais

► Devemos classificar x em π_i , se

$$\hat{d}_i(x) = \max_j \left[\hat{d}_j(x) \right], \quad j = 1, 2, \dots, k$$

Classificação em mais de duas população normais

Funções discriminantes de Fisher para mais de duas populações

- Suposição de linearidade: **Homocedasticidade!**

$$\Sigma_1 = \Sigma_2 = \dots = \Sigma_k = \Sigma$$

- A ideia é construir s combinações lineares, chamadas de **funções discriminantes canônicas**, dadas por:

$$\widehat{Y}_j = \widehat{e}_j^t x, \quad j = 1, \dots, s \leq \min(k-1, p)$$

em que $\widehat{e}_j$ é o j -ésimo autovetor corresponde ao j -ésimo maior autovalor da matriz $W^{-1}B$ e tal que $\widehat{e}_j^t W \widehat{e}_j = 1$

Classificação em mais de duas população normais

Funções discriminantes de Fisher para mais de duas populações

- Sendo a **matriz de soma de quadrados e produtos cruzados intra grupos** $W_{p \times p}$ e a **matriz de soma de quadrados e produtos cruzados entre grupos** $B_{p \times p}$, definidas respectivamente, por:

$$W = \sum_{i=1}^k \sum_{b=1}^{n_i} (x_{ib} - \bar{x}_i)(x_{ib} - \bar{x}_i)^t$$

$$B = \sum_{i=1}^k n_i (\bar{x}_i - \bar{x})(\bar{x}_i - \bar{x})^t$$

Classificação em mais de duas população normais

Funções discriminantes de Fisher para mais de duas populações

Regra de classificação

- ▶ Para cada indivíduo teremos um vetor com os seus escores nas funções, denotado por $\widehat{Y}_j$
- ▶ Teremos também, os escores das funções discriminantes aplicadas aos vetores de médias amostrais observados para cada população, denotado por $\widehat{Y}_i$

Classificação em mais de duas população normais

Funções discriminantes de Fisher para mais de duas populações

Regra de classificação

- Calcula-se a distância Euclidiana entre os vetores $\widehat{Y}_j$ e $\widehat{Y}_i$, para todo $i = 1, \dots, k$

$$d = (\widehat{Y}_j - \widehat{Y}_i)^t (\widehat{Y}_j - \widehat{Y}_i)^{\frac{1}{2}}$$

- **Classifica-se o indivíduo na população cuja distância é a menor**

Probabilidade de classificação incorreta

Os erros de classificação são definidos como:

- ▶ **Erro(i,j):** o elemento amostral pertence à população π_j mas a regra de classificação o aloca na população π_i , $i, j = 1, \dots, g$, $i \neq j$.

Probabilidade de classificação incorreta

Os erros de classificação são definidos como:

- ▶ **Erro(i,j):** o elemento amostral pertence à população π_j mas a regra de classificação o aloca na população π_i , $i, j = 1, \dots, g$, $i \neq j$.

E as probabilidades de ocorrência destes erros são estimadas por:

$$\hat{p}(i|j) = \frac{n_{ji}}{n_j}$$

onde n_{ji} é o número de elementos da população π_j classificados incorretamente pela regra na população π_i , $i, j = 1, \dots, g$, $i \neq j$.